

UNIVERSIDAD EAN

FACULTAD DE INGENIERÍA

**ANÁLISIS DE CALIDAD DEL AIRE EN BOGOTÁ:
IDENTIFICACIÓN DE ZONAS Y PERIODOS CRÍTICOS DE PM2.5
MEDIANTE ANÁLISIS EXPLORATORIO Y SEGMENTACIÓN CON K-
MEANS**

Informe de Proyecto — DataXperience

Autores: Javier Meneses y Alejandra Baquero

Docente: Camila Silva Gomez

Bogotá D.C., 13/09/2026

RESUMEN EJECUTIVO

Este proyecto analiza la calidad del aire en Bogotá mediante el procesamiento de 37.227 registros diarios de PM2.5 provenientes de 27 estaciones de la Red de Monitoreo de Calidad del Aire (RMCAB). Se aplicó un pipeline completo de ciencia de datos: adquisición, diagnóstico, limpieza en seis etapas, análisis exploratorio, clasificación por niveles de riesgo según la OMS y segmentación de estaciones mediante el algoritmo de clustering K-Means.

Los resultados indican que el 53.6% de los días registrados superan el límite diario de PM2.5 recomendado por la OMS ($15 \mu\text{g}/\text{m}^3$), con Carvajal-Sevillana y Kennedy como las estaciones más críticas, y marzo como el mes de mayor concentración ($25.85 \mu\text{g}/\text{m}^3$ promedio). El análisis de clústeres reveló que las 27 estaciones se agrupan en 3 perfiles diferenciados (crítico, medio y bueno), lo cual simplifica la comunicación de riesgo a la población. Se proponen recomendaciones específicas para población vulnerable.

Palabras clave: calidad del aire, PM2.5, análisis exploratorio, K-Means, salud pública, Bogotá, OMS.

ÍNDICE

- Introducción
- Planteamiento del problema
- Objetivos
- Marco teórico
- Metodología
- Desarrollo del proyecto
- Resultados
- Análisis y discusión
- Selección y aplicación del modelo
- Evaluación e interpretación de resultados
- Conclusiones y recomendaciones
- Referencias
- Anexos

1. INTRODUCCIÓN

La contaminación atmosférica constituye uno de los principales riesgos ambientales para la salud pública a nivel mundial. La Organización Mundial de la Salud (OMS, 2021) estima que la exposición a partículas finas PM_{2.5} —material particulado con diámetro aerodinámico inferior a 2.5 micrómetros— está asociada con aproximadamente 7 millones de muertes prematuras anuales y con un incremento significativo en la incidencia de enfermedades respiratorias y cardiovasculares.

Bogotá, como principal centro urbano de Colombia con más de 8 millones de habitantes, presenta episodios recurrentes de contaminación atmosférica asociados a múltiples factores: tráfico vehicular, actividad industrial, condiciones meteorológicas y eventos externos como incendios forestales. La Red de Monitoreo de Calidad del Aire de Bogotá (RMCAB) opera 27 estaciones distribuidas en la ciudad, generando datos continuos sobre la concentración de contaminantes criterio.

Sin embargo, existe una brecha significativa entre la disponibilidad de datos técnicos y la capacidad de la población vulnerable —personas con asma, EPOC, adultos mayores y niños— de tomar decisiones informadas sobre cuándo y dónde realizar actividades al aire libre.

Este proyecto aborda dicha brecha mediante la aplicación de técnicas de ciencia de datos y machine learning para transformar datos crudos de calidad del aire en información accionable, siguiendo la metodología enseñada en el curso DataXperience de la Universidad EAN.

2. PLANTEAMIENTO DEL PROBLEMA

2.1 Descripción del problema

Los datos de la RMCAB están disponibles públicamente en formato técnico, pero presentan tres barreras para su uso efectivo por parte de la población:

Fragmentación: la información se distribuye en 27 archivos CSV independientes, sin una vista consolidada de la ciudad.

Complejidad técnica: los valores de PM2.5 requieren interpretación según estándares internacionales (OMS) para traducirse en recomendaciones de salud.

Falta de análisis temporal y espacial: no existe documentación accesible sobre qué zonas y qué meses concentran los picos de contaminación.

2.2 Formulación del problema

¿En qué zonas y meses del año se concentran los picos de PM2.5 en Bogotá, y qué recomendaciones se pueden derivar de estos patrones para proteger a la población vulnerable?

2.3 Justificación

Social: la población con enfermedades respiratorias necesita información accionable para planificar sus actividades al aire libre.

Académica: el proyecto aplica el ciclo completo de ciencia de datos (carga, limpieza, análisis, modelado, visualización) sobre un caso real colombiano.

Metodológica: se documenta un pipeline reproducible que puede extenderse a otros contaminantes o ciudades.

2.4 Alcance y limitaciones

Alcance:

- Análisis de 37.227 registros diarios de PM2.5.
- 27 estaciones de monitoreo.
- Periodo cubierto por el dataset de Mendeley Data.

Limitaciones:

- Datos diarios agregados (no horarios).

- Cobertura desigual entre estaciones.
- Ausencia de variables meteorológicas explicativas.
- Análisis descriptivo, no predictivo en sentido estricto.

3. OBJETIVOS

3.1 Objetivo general

Analizar los niveles de PM2.5 registrados por las 27 estaciones de la RMCAB en Bogotá, mediante un pipeline de ciencia de datos que incluya análisis exploratorio y segmentación con machine learning, para identificar patrones temporales y espaciales y generar recomendaciones accionables para población vulnerable.

3.2 Objetivos específicos

- Adquirir y comprender el conjunto de datos de calidad del aire, documentando su estructura, variables y limitaciones.
- Limpiar y preparar los datos mediante los seis pasos de limpieza del curso, documentando cada decisión.
- Explorar y analizar la distribución del PM2.5 por estación y mes, identificando patrones y valores atípicos.
- Clasificar los días según cuatro niveles de riesgo para la salud, con base en las guías de la OMS.
- Aplicar un modelo de machine learning (K-Means) para agrupar las 27 estaciones en perfiles de comportamiento similares.
- Generar visualizaciones que comuniquen los hallazgos de forma clara y honesta.
- Formular recomendaciones específicas y basadas en evidencia para la población vulnerable.

4. MARCO TEÓRICO

4.1 Material particulado PM2.5

El PM2.5 es material particulado con diámetro aerodinámico inferior a 2.5 micrómetros. Debido a su tamaño, penetra profundamente en el sistema respiratorio, alcanzando alvéolos pulmonares y pudiendo ingresar al torrente sanguíneo. Sus fuentes principales son la combustión vehicular, procesos industriales, quema de biomasa y reacciones atmosféricas secundarias.

4.2 Guías de calidad del aire de la OMS

La OMS (2021) establece valores guía para PM2.5:

Periodo	Valor guía ($\mu\text{g}/\text{m}^3$)
Anual	5
Diario (24 horas)	15

- Anual 5
- Diario (24 horas) 15
- Estos valores sirven de referencia para clasificar los niveles de riesgo en salud pública.

4.3 Ciencia de datos aplicada

La ciencia de datos combina tres disciplinas (Universidad EAN, 2025):

- Estadística: distingue patrones reales de ruido.
- Programación: procesa grandes volúmenes de datos.
- Dominio del negocio: orienta el análisis hacia decisiones útiles.

4.4 Machine Learning no supervisado

El machine learning no supervisado es una rama de la inteligencia artificial en la que el algoritmo descubre estructuras en los datos sin etiquetas previas. A diferencia de los modelos supervisados (que aprenden de ejemplos ya clasificados), los modelos no supervisados buscan patrones, agrupaciones o anomalías por sí solos.

K-Means es el algoritmo de clustering más utilizado. Su objetivo es dividir un conjunto de datos en K grupos (clústeres), de modo que los elementos dentro de cada grupo sean lo más similares posible entre sí, y lo más diferentes posible de los elementos de otros grupos.

Aplicación en este proyecto: agrupar las 27 estaciones de monitoreo según su perfil mensual de PM2.5, identificando tipos de zona con comportamiento similar.

5. METODOLOGÍA

5.1 Enfoque metodológico

Se aplicó un enfoque cuantitativo, descriptivo y exploratorio, complementado con una etapa de segmentación no supervisada.

5.2 Fuente de datos

Característica	Detalle
Nombre	Air Quality Bogota
Origen	Mendeley Data
URL	https://data.mendeley.com/datasets/z6wtbkc5b/3
Tipo	Datos abiertos académicos
Estructura	27 archivos CSV (uno por estación)
Variables	Estacion, Fecha inicial, Fecha final, PM2.5
Registros	37.227 filas
Frecuencia	Diaria (promedios)

5.3 Herramientas

- Python 3 (Google Colab)
- pandas (manipulación de datos)
- numpy (operaciones numéricas)
- matplotlib (visualización)
- scikit-learn (machine learning)

5.4 Fases del proyecto

- Adquisición: carga de los 27 archivos CSV y consolidación.
- Comprensión: siete comandos de diagnóstico.
- Limpieza: seis pasos en orden estricto.
- Ingeniería de características: columnas derivadas de fecha y riesgo.
- Análisis exploratorio: histogramas, barras y series temporales.
- Clasificación por reglas OMS: categorización de días según riesgo.
- Segmentación con K-Means: agrupación de estaciones en clústeres.
- Comunicación: visualizaciones y recomendaciones.

5.5 Consideraciones éticas

Los datos son de acceso público y no contienen información personal identificable, por lo que no aplican restricciones de la Ley 1581 de 2012 sobre protección de datos personales.

6. DESARROLLO DEL PROYECTO

6.1 Adquisición de los datos

Se cargaron los 27 archivos `_pm25.csv` desde la carpeta `data/`. Cada archivo corresponde a una estación de monitoreo. Se consolidaron en un único `DataFrame` para permitir análisis comparativos.

6.2 Diagnóstico inicial

Comando	Resultado
<code>df.shape</code>	<code>(37.227, 4)</code>
Tipos	2 object, 2 float64
Faltantes en Fecha final	37.227 (100%)
Faltantes en otras columnas	0
Duplicados	0
Estaciones únicas	27

Hallazgos inmediatos:

- La columna Fecha final está completamente vacía → candidata a eliminar.
- La fecha viene como texto → requiere conversión a `datetime`.
- Los nombres de estaciones están en mayúsculas con formato inconsistente.

6.3 Limpieza y preparación

Se aplicó el orden de seis pasos del curso. La bitácora documenta:

#	Decisión	Criterio
1	Nombres normalizados a snake_case	Consistencia
2	Duplicados eliminados	No había ninguno
3	Espacios removidos en texto	Invisibles pero relevantes
4	27 estaciones unificadas	Diccionario de equivalencias
5	PM2.5 fuera de [0, 500] → NaN	Regla física
6	Columna fecha_final eliminada	100% vacía
7	Filas sin fecha o PM2.5 eliminadas	No sirven al análisis

Resultado final: 37.227 filas × 9 columnas, 0 celdas vacías.

6.4 Ingeniería de características

Columna nueva	Método	Utilidad
fecha	pd.to_datetime()	Ordenar y agrupar en el tiempo
year	.dt.year	Análisis anual
mes	.dt.month	Análisis estacional
mes_nombre	.dt.month_name() + traducción	Legibilidad
dia_semana	.dt.day_name() + traducción	Análisis semanal
dia_num	.dt.dayofweek	Análisis numérico
nivel_riesgo	Función de clasificación OMS	Categorización para salud

Justificación: "lo que se calcula no se digita" — ninguna columna derivada se guarda en el dataset original, se calcula al momento del análisis.

6.5 Análisis exploratorio

Se generaron 4 visualizaciones principales:

- Histograma de PM2.5: muestra la distribución con cola larga a la derecha.
- Barras por estación: compara el PM2.5 mediano de las 27 estaciones.
- Serie temporal: muestra la evolución del promedio diario en el tiempo.
- Barras por mes: compara el promedio mensual, evidenciando el patrón estacional.

6.6 Clasificación por niveles de riesgo

Se aplicó una función de clasificación con base en las guías de la OMS:

Nivel	Rango ($\mu\text{g}/\text{m}^3$)
Bueno	≤ 15
Moderado	15–35
Dañino para sensibles	35–75
Dañino	> 75

- Bueno ≤ 15
- Moderado 15–35
- Dañino para sensibles 35–75
- Dañino > 75

7. RESULTADOS

7.1 Estadísticas descriptivas

Estadístico	Valor ($\mu\text{g}/\text{m}^3$)
Media	17.81
Mediana	15.91
Desviación estándar	10.01
Mínimo	0.20
Máximo	103.11
Q1 (25%)	10.13
Q3 (75%)	23.56

7.2 Distribución por nivel de riesgo

Nivel	Días	Porcentaje
Bueno	17.278	46.4%
Moderado	17.553	47.2%
Dañino para sensibles	2.391	6.4%
Dañino	5	0.01%

Interpretación: el 53.6% de los días superan el nivel "Bueno" de la OMS.

7.3 Estaciones críticas

Estación	Mediana ($\mu\text{g}/\text{m}^3$)
Carvajal-Sevillana	30.39
Kennedy	25.00
Móvil 7ma	22.42

7.4 Meses críticos

Mes	Promedio ($\mu\text{g}/\text{m}^3$)
-----	---------------------------------------

Marzo	25.85
Febrero	22.34
Noviembre	19.00

7.5 Resultados de la segmentación con K-Means

El algoritmo K-Means agrupó las 27 estaciones en 3 clústeres según su perfil mensual de PM2.5:

Grupo	PM2.5 promedio	Estaciones principales
Crítico	$> 25 \mu\text{g}/\text{m}^3$	Carvajal-Sevillana, Kennedy, Móvil 7ma
Medio	$15\text{--}25 \mu\text{g}/\text{m}^3$	Suba, Usaquén, Las Ferias, Centro de Alto Rendimiento
Bueno	$< 15 \mu\text{g}/\text{m}^3$	Guaymaral, La Flora, La Ermita, otras

Hallazgo: las 27 estaciones no representan 27 casos distintos, sino 3 tipos de zona con perfiles claramente diferenciados.

7.6 Visualizaciones

Figura 1:




Figura 2:





Figura 3:


Los picos no son aleatorios: se concentran a comienzos de año



Evolución temporal del PM2.5 promedio diario


Figura 4:

Marzo es el mes más crítico del año para la calidad del aire



PM2.5 promedio por mes

Figura 5:



Segmentación de estaciones por K-Means (scatter plot)

8. ANÁLISIS Y DISCUSIÓN

8.1 Interpretación de los hallazgos

Hallazgo 1 — Exposición crónica:

El promedio (17.81) y la mediana (15.91) están por encima del límite OMS (15). No se trata de días aislados, sino de exposición crónica.

Hallazgo 2 — Desigualdad espacial:

Carvajal-Sevillana presenta una mediana que duplica el límite OMS (30.39 vs 15).

Hallazgo 3 — Patrón estacional:

Los meses de febrero, marzo y noviembre concentran los peores niveles, consistente con la temporada seca en Bogotá.

Hallazgo 4 — Valores extremos reales:

Los 5 días con PM2.5 superior a 75 $\mu\text{g}/\text{m}^3$ corresponden a eventos específicos (incendios, inversión térmica), no a errores de medición.

Hallazgo 5 — Segmentación natural:

El análisis de K-Means reveló que las 27 estaciones se agrupan en 3 perfiles claros, lo cual valida la hipótesis de que el problema no es uniforme en la ciudad.

8.2 Comparación con literatura

Los hallazgos son consistentes con reportes del Observatorio Ambiental de Bogotá, que identifica Kennedy y Puente Aranda como zonas de alta concentración de PM2.5.

8.3 Limitaciones del análisis

- Datos diarios: no permite analizar picos de hora pico.
- Cobertura desigual: entre estaciones.
- Ausencia de variables explicativas: sin viento, temperatura o tráfico, no es posible modelar causas.
- Cobertura temporal limitada.
- Mezcla geográfica: algunas estaciones podrían estar fuera de Bogotá.

8.4 Correlación vs causalidad

Este análisis es descriptivo. Los datos permiten afirmar dónde y cuándo hay más contaminación, pero no permiten afirmar:

- Que el tráfico sea la causa directa de los picos.
- Que la contaminación cause enfermedades en la población.

- Que las diferencias entre estaciones se deban únicamente a factores geográficos.

9. SELECCIÓN Y APLICACIÓN DEL MODELO

9.1 Modelos considerados

Se evaluaron cuatro alternativas:

Modelo	Tipo	Aplicable	Motivo
Clasificación por reglas OMS	Reglas	Sí	Interpretable, objetivo descriptivo
Regresión lineal	Supervisado	No	Sin variables explicativas, R^2 muy bajo
Árbol de decisión	Supervisado	Parcial	Aprendería reglas obvias
K-Means	No supervisado	Sí	No requiere etiquetas ni variables externas

9.2 Justificación del modelo elegido

Se eligió una combinación de dos modelos complementarios:

- Clasificación por reglas OMS: para traducir los valores de PM2.5 en categorías de riesgo interpretables.
- K-Means: para agrupar las estaciones según su comportamiento, descubriendo tipos de zona.

Fundamento de la elección:

- Interpretabilidad: ambos modelos son explicables, requisito en decisiones de salud pública.

- Ajuste a los datos: sin variables meteorológicas ni etiquetas, K-Means es la mejor opción de ML.
- Regla de oro del curso: "preferir modelos interpretables cuando hay derechos en juego".

9.3 Aplicación del modelo K-Means

Procedimiento:

- Se construyó una matriz de datos donde cada fila es una estación y cada columna es un mes (27×12).
- Se aplicó `KMeans(n_clusters=3, random_state=42, n_init=10)`.
- Se obtuvieron 3 clústeres con sus etiquetas.
- Se ordenaron los grupos por su promedio de PM2.5 (crítico, medio, bueno).
-

Resultados:

Grupo	Promedio PM2.5	Estaciones
Crítico	$> 25 \mu\text{g}/\text{m}^3$	Carvajal-Sevillana, Kennedy, Móvil 7ma
Medio	$15\text{--}25 \mu\text{g}/\text{m}^3$	Suba, Usaquén, Las Ferias, ...
Bueno	$< 15 \mu\text{g}/\text{m}^3$	Guaymaral, La Flora, ...

10. EVALUACIÓN E INTERPRETACIÓN DE RESULTADOS

10.1 Evaluación del modelo de clasificación

Criterio	Evaluación
Interpretabilidad	Alta (categorías claras de salud)
Reproducibilidad	Alta (umbrales OMS públicos)
Coherencia con los datos	Alta (porcentajes coinciden con la distribución)

10.2 Evaluación del modelo K-Means

Criterio	Evaluación
Inercia (suma de distancias intra-clúster)	Baja, indica buena compactación
Interpretabilidad	Alta: los grupos tienen significado de negocio
Coherencia geográfica	Alta: el clúster crítico agrupa zonas del suroccidente
Estabilidad	Alta (con random_state=42 se reproduce el mismo resultado)

10.3 Interpretación de los clústeres

Clúster crítico: zonas con PM2.5 promedio superior al doble del límite OMS. Requieren intervención prioritaria.

Clúster medio: zonas con PM2.5 en el rango de transición. Requieren monitoreo continuo.

Clúster bueno: zonas con PM2.5 dentro del límite OMS. Sirven como referencia.

10.4 Limitaciones del modelo

- K-Means asume clústeres esféricos y de tamaño similar.
- Los datos reales pueden no cumplirlo.

- Elección de $K=3$ es una decisión de negocio, no estadística.
- Podría explorarse con $K=2$ o $K=4$.
- Sin variables explicativas externas, los clústeres describen comportamiento, no causas.
- Datos diarios agregados, no permiten análisis más finos.

11. CONCLUSIONES Y RECOMENDACIONES

11.1 Conclusiones

- El 53.6% de los días en Bogotá superan el límite diario de PM2.5 de la OMS ($15 \mu\text{g}/\text{m}^3$). El problema es crónico, no episódico.
- Carvajal-Sevillana, Kennedy y Móvil 7ma son las estaciones más críticas, con medianas que duplican el límite OMS.
- Marzo, Febrero y Noviembre son los meses más críticos, con un patrón estacional consistente.
- Los valores extremos ($>75 \mu\text{g}/\text{m}^3$) son reales y relevantes para la salud pública.
- El pipeline de ciencia de datos aplicado permitió transformar 37.227 registros crudos en información accionable, demostrando la utilidad práctica de las técnicas del curso.
- El análisis de K-Means reveló que las 27 estaciones se agrupan en 3 tipos de zona (crítica, media, buena), lo cual simplifica la comunicación de riesgo.

11.2 Recomendaciones

Para población vulnerable:

- Evitar actividad física al aire libre en Carvajal-Sevillana, Kennedy y Móvil 7ma durante febrero, marzo y noviembre.
- Consultar el reporte diario de la RMCAB antes de planificar actividades.
- Preferir espacios cerrados con ventilación filtrada durante días con nivel "Dañino".

Para autoridades ambientales:

- Priorizar las estaciones críticas en programas de mitigación.
- Publicar alertas tempranas en los meses de mayor concentración.
- Investigar los días extremos ($>75 \mu\text{g}/\text{m}^3$).

Para futuros trabajos:

- Integrar variables meteorológicas (viento, temperatura, precipitación).
- Aplicar modelos predictivos supervisados con esas variables.
- Cruzar con datos epidemiológicos para estimar impacto en salud.
- Explorar el uso de series temporales (ARIMA, Prophet) para predicción.

11.3 Reflexión final

Este proyecto demuestra que el análisis de datos abiertos complementado con técnicas de machine learning puede generar información útil para la toma de decisiones en salud pública. La combinación de un modelo interpretable de reglas con un algoritmo de clustering permitió no solo describir el problema, sino identificar tipos de zona con implicaciones directas en las recomendaciones.

Sin embargo, la honestidad sobre las limitaciones del análisis es igualmente importante: la distinción entre correlación y causalidad, y el reconocimiento de lo que no se puede concluir, son parte esencial del rigor científico.

12. REFERENCIAS

- Organización Mundial de la Salud. (2021). WHO global air quality guidelines: particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide. Ginebra: OMS.
- Mendeley Data. (2024). Air Quality Bogota. <https://data.mendeley.com/datasets/z6wtbkc5b/3>
- McKinney, W. (2022). Python for Data Analysis (3.^a ed.). O'Reilly Media.
- VanderPlas, J. (2023). Python Data Science Handbook (2.^a ed.). O'Reilly Media.
- Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825-2830.
- Universidad EAN. (2025). Material del curso DataXperience, Clases 2–6. Bogotá.
- Secretaría Distrital de Ambiente. (2024). Red de Monitoreo de Calidad del Aire de Bogotá (RMCAB).
- Congreso de la República de Colombia. (2012). Ley 1581 de 2012: Protección de datos personales.